TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT
ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

BÁO CÁO BÀI TẬP LỚN
MÔN: NHÀ KHO DỮ LIỆU VÀ TÍCH HỢP

XÂY DỰNG NHÀ KHO DỮ LIỆU VÀ HỆ THỐNG BI CHO TRUNG TÂM ĐÀO TẠO

Giảng viên hướng dẫn: [Bổ sung]

Nhóm thực hiện: [Tên nhóm]

Thành viên 1: [Họ tên – MSSV]

Thành viên 2: [Họ tên – MSSV]

TP. Hồ Chí Minh, năm 2026

TÓM TẮT BÁO CÁO

Đồ án đề xuất xây dựng một kiến trúc nhà kho dữ liệu phục vụ quản trị trung tâm đào tạo, tập trung vào vòng đời từ marketing, khách hàng tiềm năng (lead), đăng ký khóa học, học tập đến tư vấn hướng nghiệp. Bài toán xuất phát từ việc dữ liệu nghiệp vụ thường được quản lý bằng các bảng riêng biệt, dẫn đến khó đối chiếu chỉ tiêu, trùng lặp thông tin và mất thời gian lập báo cáo.

Giải pháp được thiết kế theo hướng tích hợp dữ liệu bằng Python/Pandas, tổ chức các lớp Bronze, Silver và Gold, xây dựng mô hình chiều Star Schema, dùng BigQuery làm nền tảng kho dữ liệu đích, dbt để quản lý phép biến đổi SQL và kiểm thử, cùng dashboard BI để trình bày chỉ số quản trị. Ba Data Mart được đề xuất gồm Marketing Analytics, Enrollment & Revenue Analytics và Learning Analytics; dữ liệu tư vấn hướng nghiệp được tích hợp như một miền phân tích bổ sung.

Bộ dữ liệu đi kèm là dữ liệu tổng hợp mô phỏng có chủ đích, không phải hồ sơ của học viên thật. Các lỗi như khóa trùng, giá trị thiếu, trạng thái không thống nhất, số tiền âm và điểm ngoài miền hợp lệ được đưa vào dữ liệu nguồn để minh họa quy trình kiểm soát chất lượng. Notebook chạy cục bộ/Colab có thể tạo các tệp Silver và tính các chỉ số trên dữ liệu mô phỏng.

Trạng thái tại thời điểm bàn giao bộ khung: mã nguồn, dữ liệu mô phỏng, từ điển dữ liệu, mô hình SQL/dbt, dashboard local và tài liệu báo cáo đã được chuẩn bị. Việc tạo Google Cloud Project, nạp bảng lên BigQuery, chạy dbt trên cloud và chụp kết quả thực nghiệm thật vẫn là các bước cần người học thực hiện. Vì vậy, báo cáo không tuyên bố các bước cloud đã chạy thành công.

1. GIỚI THIỆU

1.1. Bối cảnh. Các trung tâm đào tạo cần phối hợp hoạt động marketing, tư vấn tuyển sinh, tổ chức lớp học và hướng nghiệp. Mỗi hoạt động có thể tạo ra dữ liệu ở định dạng và thời điểm khác nhau. Nếu các bộ phận duy trì các tệp riêng, nhà quản lý sẽ khó trả lời nhất quán câu hỏi về hiệu quả chiến dịch, tỷ lệ chuyển đổi, doanh thu và chất lượng học tập.

1.2. Ý nghĩa. Nhà kho dữ liệu (Data Warehouse) cung cấp kho dữ liệu tích hợp, có lịch sử và được tổ chức cho phân tích. Khác với cơ sở dữ liệu giao dịch tối ưu cho việc ghi nhận từng giao dịch, kho dữ liệu ưu tiên truy vấn tổng hợp, so sánh theo thời gian và phân tích đa chiều. BI chuyển dữ liệu đã chuẩn hóa thành chỉ số dễ hiểu, hỗ trợ ra quyết định dựa trên bằng chứng.

1.3. Mục tiêu tổng quát. Thiết kế và hiện thực hóa nguyên mẫu pipeline tích hợp dữ liệu cho trung tâm đào tạo; mô tả quy tắc chất lượng; xây dựng mô hình chiều và Data Mart; minh họa phân tích bằng SQL và dashboard.

1.4. Mục tiêu cụ thể. (i) Tạo bộ dữ liệu nguồn liên kết được bằng khóa; (ii) khám phá và ghi nhận lỗi dữ liệu; (iii) xây dựng quy trình làm sạch và kiểm tra khóa ngoại; (iv) thiết kế Fact/Dimension theo grain rõ ràng; (v) cung cấp mô hình SQL/dbt; (vi) tạo dashboard mẫu; (vii) đưa ra khuyến nghị có điều kiện dựa trên chỉ số tính từ dữ liệu mô phỏng.

1.5. Phạm vi. Đồ án tập trung vào phân tích quản trị, không xây dựng hệ thống quản lý học viên vận hành đầy đủ. Dữ liệu nhân khẩu học chỉ gồm các thuộc tính tối thiểu để minh họa; không có tên, số điện thoại, email hoặc thông tin định danh thực. Không xây dựng mô hình dự đoán hoặc ra quyết định tự động về học viên.

1.6. Câu hỏi nghiên cứu. Hiệu quả marketing được đo thế nào? Cần tích hợp những miền dữ liệu nào để phân tích vòng đời học viên? Mô hình Star Schema giúp truy vấn KPI ra sao? Những kiểm thử nào cần có để hạn chế sai lệch trong báo cáo quản trị?

2. MÔ TẢ TỔNG QUAN DỮ LIỆU

2.1. Nguồn và tính chất dữ liệu. Bộ dữ liệu được sinh bằng mã Python với seed cố định để có thể tái tạo. Tất cả giá trị là mô phỏng phục vụ học tập; không được xem là bằng chứng về hoạt động của một trung tâm thật. Các tệp nguồn gồm students.csv, campaigns.csv, leads.csv, enrollments.csv, courses.csv, learning_records.csv và career_guidance.csv.

2.2. Mô tả từng miền. Students lưu hồ sơ học viên ở mức một dòng/học viên. Campaigns lưu thông tin chiến dịch và chi phí. Leads lưu mỗi khách hàng tiềm năng và trạng thái xử lý. Enrollments lưu mỗi lượt đăng ký khóa học, giá niêm yết, giảm giá, số tiền ghi nhận và trạng thái. Learning records lưu từng buổi học hoặc lần ghi nhận tiến độ. Career guidance lưu từng phiên tư vấn hướng nghiệp.

2.3. Đặc trưng dữ liệu. Các khóa ID dạng chuỗi được sử dụng để liên kết bảng. Các trường ngày được biểu diễn theo ISO YYYY-MM-DD. Trường tiền tệ dùng đơn vị VND và cần được ép kiểu số trước khi tính tổng. Điểm đánh giá nằm trong khoảng 0–10; điểm hài lòng nằm trong khoảng 1–5. Trạng thái là biến phân loại cần chuẩn hóa chữ hoa/thường và khoảng trắng.

2.4. Lỗi được cài vào dữ liệu nguồn. Một số bản ghi có giới tính thiếu, tên quận có khoảng trắng hoặc chữ thường, khối lớp có tiền tố văn bản, lead bị trùng, trạng thái viết thường, số lần liên hệ âm, mã học viên không tồn tại, chi phí hoặc số tiền âm, điểm đánh giá lớn hơn 10 và điểm hài lòng vượt miền 1–5. Đây là lỗi kiểm thử có chủ đích, không phải lỗi thu thập từ người thật.

2.5. Khám phá dữ liệu. Notebook cung cấp số dòng, số cột, tổng ô thiếu và biểu đồ phân bố trạng thái lead, số lượt đăng ký theo tháng. Khi chạy, cần lưu ảnh chụp hoặc xuất bảng thống kê thực tế để đưa vào báo cáo cuối. Số lượng dòng có thể được tính trực tiếp từ các tệp trong gói; các số đo đó chỉ mô tả dữ liệu tổng hợp.

2.6. Giới hạn diễn giải. Vì dữ liệu được tạo ngẫu nhiên theo quy tắc, quan hệ giữa chiến dịch, doanh thu và điểm học tập không đại diện cho quan hệ nhân quả. Các biểu đồ chỉ chứng minh pipeline hoạt động về mặt kỹ thuật, không thể dùng để đưa ra quyết định ngân sách thật.

Tệp	Ý nghĩa	Grain
students.csv	Hồ sơ học viên	Một dòng/học viên
campaigns.csv	Chiến dịch marketing	Một dòng/chiến dịch
leads.csv	Khách hàng tiềm năng	Một dòng/lead
enrollments.csv	Đăng ký khóa học	Một dòng/lượt đăng ký
learning_records.csv	Buổi học/lần ghi nhận	Một dòng/bản ghi học tập
career_guidance.csv	Tư vấn hướng nghiệp	Một dòng/buổi tư vấn

3. PHƯƠNG PHÁP LUẬN NGHIÊN CỨU

3.1. Cách tiếp cận. Đồ án dùng quy trình nhiều lớp: nguồn → Bronze → Silver → Gold → Data Mart/BI. Bronze giữ bản sao gần với nguồn để truy vết; Silver áp dụng chuẩn hóa và quy tắc chất lượng; Gold tổ chức mô hình phân tích. Tách lớp giúp phân biệt dữ liệu ban đầu với dữ liệu đã biến đổi và tạo khả năng kiểm tra lại.

3.2. Ingestion. Tệp CSV được đọc bằng Pandas trong notebook. Khi chuyển lên BigQuery, mỗi tệp nguồn được nạp thành một bảng Bronze. Cần ghi lại tên tệp, thời điểm nạp, số dòng, cấu hình dấu phân cách, encoding và schema. Trong phiên bản nâng cao có thể bổ sung metadata ingestion_timestamp và batch_id.

3.3. Làm sạch. Quy tắc gồm chuẩn hóa văn bản, chuẩn hóa trạng thái, chuyển kiểu dữ liệu, xử lý thiếu, loại trùng theo khóa nghiệp vụ, kiểm tra miền giá trị và kiểm tra khóa ngoại. Không nên xóa dữ liệu thiếu một cách tùy tiện; cần xác định giá trị có thể suy ra, có thể gán nhãn chưa xác định hay phải loại bỏ.

3.4. Xử lý khóa ngoại. Lead phải tham chiếu học viên và chiến dịch tồn tại. Enrollment phải tham chiếu học viên, chiến dịch và khóa học; lead_id có thể null với đăng ký trực tiếp. Learning record phải tham chiếu enrollment, student và course hợp lệ. Career guidance phải tham chiếu student. Bản ghi vi phạm cần được loại, cách ly hoặc đưa vào bảng lỗi tùy yêu cầu.

3.5. ETL và ELT. Trong notebook, dữ liệu được đọc, biến đổi và xuất thành các tệp Silver, đây là cách minh họa ETL ở quy mô nhỏ. Trong BigQuery, có thể nạp dữ liệu thô trước rồi dùng SQL/dbt để biến đổi bên trong kho, đây là mô hình ELT. Hai cách có thể cùng tồn tại: Python hỗ trợ kiểm tra ban đầu, dbt quản lý biến đổi lặp lại ở kho dữ liệu.

3.6. Kiểm thử. Các kiểm tra tối thiểu gồm not_null và unique trên khóa; kiểm tra miền điểm, tiền và số lần liên hệ; kiểm tra quan hệ giữa Fact và Dimension; đối chiếu số dòng đầu vào/đầu ra; kiểm tra tổng tiền giữa nguồn và bảng Gold. Kiểm thử cần có kết quả pass/fail được lưu lại, không chỉ mô tả bằng lời.

4. KIẾN TRÚC VÀ LUỒNG DỮ LIỆU

4.1. Kiến trúc logic. Data source gồm CSV/Excel hoặc hệ thống nghiệp vụ. Lớp ingestion tiếp nhận dữ liệu. Bronze giữ dữ liệu thô. Silver làm sạch và chuẩn hóa. Gold gồm Dimension, Fact và các view Data Mart. Dashboard truy vấn Gold hoặc các Data Mart đã tổng hợp.

4.2. Bronze. Lớp này bảo toàn dữ liệu đầu vào để có thể tái xử lý khi quy tắc thay đổi. Không nên sửa trực tiếp dữ liệu gốc. Cần giữ lại bản gốc, ngày nạp và mô tả schema. Với dữ liệu nhạy cảm, quyền truy cập Bronze phải được hạn chế hơn các lớp phân tích.

4.3. Silver. Mỗi mô hình Silver có trách nhiệm rõ ràng: chuẩn hóa dữ liệu, ép kiểu, xử lý khóa trùng và kiểm tra tham chiếu. Các phép biến đổi cần được ghi trong code để tái lập. Giá trị không hợp lệ không nên bị âm thầm thay đổi mà không có quy tắc và nhật ký.

4.4. Gold. Gold chứa mô hình chiều được tối ưu cho phân tích. Các dimension mô tả đối tượng như học viên, khóa học, chiến dịch và thời gian. Các fact lưu sự kiện ở grain đã xác định. Bảng tổng hợp hoặc view Data Mart hỗ trợ truy vấn nhanh và tạo ngữ nghĩa thống nhất cho KPI.

4.5. Công nghệ. Python/Pandas hỗ trợ profiling và ETL nhỏ; BigQuery là nền tảng lưu trữ phân tích được đề xuất; dbt tổ chức mô hình SQL và test; Streamlit cung cấp dashboard local mẫu. Người học cần tự tạo tài khoản/project và xác thực trước khi thực hiện các bước cloud. Không cần đưa khóa dịch vụ vào mã nguồn.

4.6. Tính mở rộng. Với dữ liệu lớn hơn, có thể bổ sung điều phối bằng Airflow/Prefect, incremental models, partition theo ngày, clustering theo khóa thường truy vấn, kiểm soát schema evolution và cơ chế retry. Các phần này là hướng mở rộng, không được xem là đã hiện thực hóa trong gói ban đầu.

5. THIẾT KẾ STAR SCHEMA

5.1. Nguyên tắc. Star Schema đặt một bảng Fact ở trung tâm và các Dimension xung quanh. Grain của Fact phải được phát biểu bằng một câu rõ ràng trước khi tạo bảng. Mỗi Fact không nên trộn các sự kiện có mức chi tiết khác nhau vì sẽ gây nhân bản số tiền hoặc số lượng khi join.

5.2. Dim_Date. Mỗi dòng đại diện một ngày lịch, có date_key dạng YYYYMMDD, full_date, ngày trong tháng, tháng, quý và năm. Dimension này giúp phân tích xu hướng theo ngày, tháng, quý và năm. Với các sự kiện khác nhau, có thể dùng role-playing dimensions như enrollment_date_key và session_date_key.

5.3. Dim_Student. Một dòng cho mỗi học viên trong phiên bản cơ bản, gồm student_id, gender, date_of_birth, grade, school_id và district. Nếu cần lưu lịch sử chuyển trường hoặc thay đổi khối lớp, có thể mở rộng theo Slowly Changing Dimension Type 2 với effective_start, effective_end và is_current.

5.4. Dim_Course và Dim_Campaign. Dim_Course mô tả môn học, nhóm môn, cấp học và học phí chuẩn. Dim_Campaign mô tả tên chiến dịch, kênh, ngày bắt đầu/kết thúc và các chỉ tiêu marketing. Nếu chi phí chỉ có ở cấp chiến dịch chứ không ở cấp ngày, không nên nhân toàn bộ chi phí đó cho mỗi ngày khi join.

5.5. Fact_Lead. Grain: một dòng cho mỗi lead_id. Measures/attributes gồm contact_attempts, first_response_hours và is_converted. Trạng thái là dimension-like attribute; tỷ lệ chuyển đổi được tính ở tầng tổng hợp bằng số lead chuyển đổi chia số lead hợp lệ.

5.6. Fact_Enrollment. Grain: một dòng cho mỗi enrollment_id. Lưu list_price_vnd, discount_vnd, amount_paid_vnd và recognized_revenue_vnd. Quy tắc hiện tại ghi nhận doanh thu bằng 0 với đơn Cancelled/Refunded; đây là giả định mô phỏng cần được thay bằng chính sách kế toán thực tế nếu triển khai doanh nghiệp.

5.7. Fact_Learning. Grain: một dòng cho mỗi learning_record_id, tương ứng một buổi học/lần ghi nhận. Lưu attendance_status, assessment_score và progress_percent. Không lấy trung bình điểm trực tiếp sau khi join với bảng enrollment nếu join làm lặp bản ghi; phải tổng hợp theo grain phù hợp.

5.8. Fact_Career_Guidance. Grain: một dòng cho mỗi guidance_id. Lưu loại tư vấn, tư vấn viên, kết quả và điểm hài lòng. Dữ liệu này có thể phân tích nhu cầu tư vấn theo khối lớp hoặc khu vực nhưng cần tránh diễn giải điểm hài lòng như kết quả nghề nghiệp dài hạn.

Bảng	Grain	Measures/thuộc tính chính
Fact_Lead	1 lead	contact_attempts, response_hours,

		is_converted
Fact_Enrollment	1 enrollment	list_price, discount, amount_paid, recognized_revenue
Fact_Learning	1 learning record	attendance, score, progress
Fact_Career_Guidance	1 guidance session	type, outcome, satisfaction
Dim_Date	1 calendar date	day, month, quarter, year
Dim_Student	1 student	gender, grade, school, district
Dim_Course	1 course	name, subject group, level
Dim_Campaign	1 campaign	name, channel, start/end date

6. THIẾT KẾ PIPELINE ETL/ELT

6.1. Bước 1 — đọc dữ liệu. Notebook kiểm tra tệp tồn tại, đọc CSV và in số dòng/cột, giá trị thiếu. Khi chạy trên Colab, người dùng cần upload thư mục data/raw hoặc sửa RAW_DIR tương ứng. Nếu tệp thiếu, notebook dừng với lỗi có thông báo rõ.

6.2. Bước 2 — chuẩn hóa. Chuẩn hóa chữ hoa/thường và khoảng trắng cho trạng thái, quận huyện, loại tư vấn; ép kiểu ngày và số; chuẩn hóa grade về 10/11/12. Cần kiểm tra các giá trị sau chuẩn hóa để phát hiện trường hợp không nhận diện được.

6.3. Bước 3 — xử lý thiếu và miền giá trị. Gender thiếu được gán 'Chưa xác định'. Giá trị tiền âm được chuyển thành null rồi xử lý theo quy tắc từng cột. Điểm ngoài 0–10 và điểm hài lòng ngoài 1–5 được đặt null. Trong triển khai thực tế, nên ghi các bản ghi lỗi vào quarantine thay vì chỉ loại bỏ.

6.4. Bước 4 — khử trùng lặp. Sử dụng khóa nghiệp vụ như student_id, campaign_id, lead_id, enrollment_id, learning_record_id và guidance_id. Nếu nguồn có nhiều phiên bản cùng khóa, phải có quy tắc chọn bản ghi mới nhất dựa trên timestamp đáng tin cậy; trong dữ liệu mô phỏng, quy tắc được đơn giản hóa.

6.5. Bước 5 — kiểm tra khóa ngoại. Dùng tập khóa hợp lệ từ dimension hoặc bảng cha để kiểm tra liên kết. Các enrollment có lead_id không tồn tại có thể được coi là đăng ký trực tiếp và để null, nhưng student_id, campaign_id và course_id không hợp lệ phải được xử lý theo quy tắc rõ ràng.

6.6. Bước 6 — xuất Silver. Tạo các tệp *_clean.csv. Đây là checkpoint để so sánh dữ liệu trước/sau và có thể dùng để nạp lên BigQuery. Lưu ý: nếu chạy lại notebook, thư mục đầu ra được ghi đè; nên giữ bản raw không đổi.

6.7. Bước 7 — nạp và mô hình hóa trong BigQuery/dbt. Tạo ba dataset Bronze/Silver/Gold. Upload các bảng raw. Cấu hình profile dbt bằng OAuth. Thay project ID placeholder trong YAML/SQL. Chạy dbt debug, dbt run và dbt test, sau đó lưu log. Vị trí dataset/location phải thống nhất giữa BigQuery và profile.

6.8. Xử lý lỗi và phục hồi. Trong bản sản phẩm thực tế, pipeline nên có log thời điểm bắt đầu/kết thúc, số dòng đọc/ghi, số lỗi, thông báo ngoại lệ và mã batch. Khi một bước thất bại, cần tránh cập nhật một phần Gold mà không đánh dấu trạng thái. Có thể dùng staging table và swap/transaction phù hợp.

7. CẤU HÌNH BIGQUERY VÀ DBT

7.1. Tạo Google Cloud Project. Người dùng đăng nhập Google Cloud Console, tạo project, ghi lại Project ID, bật billing nếu dịch vụ yêu cầu và bật BigQuery API. Quyền truy cập cần theo nguyên tắc tối thiểu. Không chia sẻ thông tin đăng nhập hoặc service account key.

7.2. Tạo datasets. Tạo education_dw_bronze, education_dw_silver và education_dw_gold ở cùng location. Location của dataset phải tương thích với cấu hình dbt. Dùng SQL trong sql/00_create_datasets.sql sau khi thay YOUR_GCP_PROJECT_ID.

7.3. Nạp CSV. Tạo bảng tương ứng với tên file trong Bronze, đánh dấu dòng tiêu đề và kiểm tra schema. Trường ngày và tiền có thể được nạp thành STRING ở Bronze để bảo toàn nguồn, sau đó SAFE_CAST ở Silver. Lưu ý BigQuery có giới hạn và chi phí phụ thuộc lượng dữ liệu truy vấn; với bộ mô phỏng nhỏ, chi phí thường thấp nhưng người dùng vẫn cần theo dõi.

7.4. Cài dbt. Tạo môi trường Python, cài dbt-bigquery, cấu hình profiles.yml bằng phương thức OAuth/Application Default Credentials. profiles.example.yml được cung cấp như mẫu. Không commit profiles.yml chứa thông tin nhạy cảm vào kho mã nguồn.

7.5. Khai báo source và models. sources.yml định nghĩa các bảng Bronze; models staging chuẩn hóa dữ liệu; models marts tạo bảng phân tích. Cần rà soát schema đích vì cấu hình schema trong dbt có thể được ghép với custom schema theo quy tắc đặt tên. Nếu thay đổi cấu hình, cập nhật đồng bộ tài liệu.

7.6. Lệnh kiểm tra. Chạy dbt debug để kiểm tra kết nối, dbt run để tạo models và dbt test để chạy kiểm thử. Nếu gặp lỗi permission, project ID, dataset location hoặc schema, lưu thông báo lỗi và sửa theo nguyên nhân. Không ghi kết quả thành công cho tới khi có log thực tế.

7.7. Lưu bằng chứng. Bằng chứng triển khai gồm ảnh dataset, danh sách bảng, kết quả dbt debug/run/test, số dòng mỗi bảng và truy vấn KPI. Ảnh phải lấy từ môi trường thật của nhóm; các sơ đồ trong báo cáo chỉ là thiết kế tham chiếu.

8. DATA MART VÀ KPI QUẢN TRỊ

8.1. Marketing Analytics. Phân tích tổng lead, lead chuyển đổi, conversion rate, marketing spend và cost per lead theo chiến dịch/kênh. Chi phí chiến dịch có thể được lặp lại nếu join với nhiều lead, vì vậy cần tổng hợp theo campaign trước khi cộng chi phí. Không cộng chi phí chiến dịch lặp theo từng lead.

8.2. Enrollment & Revenue Analytics. Phân tích lượt đăng ký theo môn học, thời gian và trạng thái; tổng doanh thu ghi nhận; tổng giảm giá; tỷ lệ hủy/hoàn. Cần xác định rõ revenue policy. Trong dữ liệu mô phỏng, Cancelled và Refunded được gán doanh thu ghi nhận bằng 0, còn amount_paid_vnd nguồn vẫn được giữ để kiểm tra.

8.3. Learning Analytics. Phân tích tỷ lệ chuyên cần, điểm đánh giá trung bình và tiến độ. Tỷ lệ chuyên cần = số bản ghi Present / tổng bản ghi buổi học hợp lệ. Điểm trung bình cần bỏ qua giá trị null và luôn đi kèm cỡ mẫu để tránh kết luận từ số lượng quá nhỏ.

8.4. Career Guidance Analytics. Đếm phiên tư vấn theo loại, kết quả và thời gian; tính điểm hài lòng trung bình khi có dữ liệu hợp lệ. Không xem số buổi tư vấn là thước đo trực tiếp của chất lượng hướng nghiệp; cần kết hợp khảo sát theo dõi dài hạn nếu có.

8.5. Định nghĩa KPI. Tổng lead = số lead_id duy nhất. Converted leads = số lead có trạng thái Converted. Conversion rate = converted leads / total leads. CPL = chi phí marketing / total leads, với điều kiện total leads > 0. Attendance rate = số phiên Present / tổng phiên có trạng thái hợp lệ. Average score = trung bình assessment_score hợp lệ.

8.6. Nguyên tắc so sánh. Khi so sánh chiến dịch, cần xem xét thời gian chạy, kênh, ngân sách và độ trễ chuyển đổi. Không nên xếp hạng chiến dịch chỉ dựa trên tổng lead nếu mục tiêu là doanh thu hoặc chất lượng lead. Khi số lượng nhỏ, cần trình bày cỡ mẫu và cảnh báo bất định.

KPI	Công thức	Cảnh báo
Lead conversion rate	Converted leads / total leads	Chuẩn hóa status, denominator > 0
Cost per Lead	Campaign spend / leads	Chi phí không bị nhân bởi join
Recognized revenue	SUM(revenue recognized)	Áp dụng chính sách hủy/hoàn
Attendance rate	Present sessions / valid sessions	Khử trùng lặp buổi học
Average score	AVG(valid score)	Điểm trong 0–10, kèm cỡ mẫu

9. DASHBOARD VÀ THIẾT KẾ TRỰC QUAN

9.1. Mục tiêu dashboard. Cung cấp một điểm truy cập trực quan để người quản lý theo dõi KPI tổng quan, đi sâu theo chiến dịch, môn học, trạng thái đăng ký và kết quả học tập. Dashboard prototype dùng Streamlit đọc các tệp Silver để có thể chạy local trước khi thiết lập cloud.

9.2. Trang tổng quan. Các thẻ KPI gợi ý gồm tổng lead, lead chuyển đổi, conversion rate và doanh thu ghi nhận. Cần chú thích rõ các số liệu được tính từ dữ liệu mô phỏng. Các bộ lọc nên gồm thời gian, kênh, môn học và trạng thái.

9.3. Trang marketing. Biểu đồ cột so sánh lead theo chiến dịch và bảng chi tiết chi phí, kênh, số lead. Bổ sung conversion rate và CPL sau khi kiểm tra cách tính. Không dùng biểu đồ có tổng chi phí bị nhân lên do join sai grain.

9.4. Trang đăng ký/doanh thu. Biểu đồ doanh thu theo môn học và bảng lượt đăng ký theo trạng thái. Nên có biểu đồ theo tháng để quan sát xu hướng. Nếu doanh thu có giá trị bất thường, đối chiếu với bảng nguồn và quy tắc ghi nhận trước khi giải thích.

9.5. Trang học tập. Trình bày tỷ lệ chuyên cần và điểm đánh giá trung bình theo khóa học. Khi so sánh môn học, cần hiển thị số bản ghi có điểm để người xem hiểu độ tin cậy của giá trị trung bình.

9.6. Trang tư vấn. Hiển thị số buổi theo loại tư vấn và phân bố kết quả. Có thể dùng biểu đồ thanh hoặc bảng tổng hợp. Không hiển thị dữ liệu định danh cá nhân; chỉ trình bày thống kê tổng hợp.

9.7. Chạy dashboard. Từ thư mục gốc, cài `pip install -r dashboard/requirements.txt`, sau đó chạy `streamlit run dashboard/app.py`. Dashboard prototype không kết nối BigQuery; nếu muốn kết nối BigQuery, cần bổ sung client, xác thực an toàn và truy vấn Data Mart.

10. THỬ NGHIỆM VÀ ĐÁNH GIÁ CHẤT LƯỢNG

10.1. Thiết kế thử nghiệm. Thử nghiệm được chia thành kiểm thử xử lý dữ liệu local và triển khai cloud. Local kiểm tra khả năng đọc CSV, biến đổi, tạo tệp Silver, tính KPI và chạy dashboard. Cloud kiểm tra nạp bảng, kết nối dbt, tạo mô hình và test. Hai lớp cần được báo cáo tách biệt.

10.2. Kiểm tra tính duy nhất. Các khóa student_id, campaign_id, lead_id, enrollment_id, learning_record_id và guidance_id cần duy nhất ở bảng tương ứng. Notebook dùng assert để dừng nếu khóa trùng còn tồn tại.

10.3. Kiểm tra miền giá trị. Điểm đánh giá sau làm sạch nằm trong 0–10; điểm hài lòng trong 1–5; số tiền và chi phí không âm; contact_attempts không âm; trạng thái điểm danh được chuẩn hóa. Những kiểm tra này chứng minh dữ liệu tuân theo quy tắc kỹ thuật, không bảo đảm rằng nguồn mô phỏng giống thực tế.

10.4. Kiểm tra tham chiếu. Tất cả khóa student_id/campaign_id/course_id/enrollment_id trong các bảng sự kiện phải tham chiếu được đến bản ghi hợp lệ. Riêng lead_id có thể null nếu enrollment không gắn với lead. Khi mở rộng, cần thêm test relationships trong dbt.

10.5. Đối chiếu số dòng. Lưu số dòng raw, số dòng sau khử trùng lặp, số dòng bị loại do khóa ngoại và số dòng Silver. Nên tạo bảng audit theo từng batch. Không chỉ so sánh tổng số dòng; cần phân biệt các loại loại bỏ để giải thích được chênh lệch.

10.6. Kết quả cần ghi nhận. Khi nhóm chạy notebook, hãy chép các con số thực tế vào bảng: số dòng từng bảng raw/silver, số bản ghi lỗi phát hiện, số bản ghi loại/sửa, số dòng Fact/Dimension, kết quả test pass/fail. Các giá trị này không được điền trước khi chạy.

10.7. Đánh giá cloud. Chưa có Google Cloud Project nên trạng thái BigQuery/dbt cloud được xem là chưa thực thi. Khi thiết lập xong, cập nhật ngày chạy, phiên bản dbt, region, log và ảnh chụp. Nếu không hoàn tất cloud, phải mô tả rõ phạm vi prototype local và lý do.

11. PHÂN TÍCH KẾT QUẢ VÀ HỖ TRỢ RA QUYẾT ĐỊNH

11.1. Diễn giải marketing. Khi có kết quả thật từ dữ liệu mô phỏng, nhóm có thể xác định kênh có nhiều lead nhất và kênh có conversion rate cao nhất. Hai kết quả có thể khác nhau. Đề xuất ưu tiên cần dựa trên chi phí, tỷ lệ chuyển đổi và mục tiêu kinh doanh, không chỉ dựa trên số lượng lead.

11.2. Diễn giải doanh thu. So sánh doanh thu ghi nhận theo môn học và trạng thái giúp nhận biết nhóm khóa học có đóng góp doanh thu lớn. Tuy nhiên, doanh thu cao không đồng nghĩa lợi nhuận cao nếu chưa có chi phí giảng dạy, chi phí vận hành và chi phí marketing được phân bổ đúng.

11.3. Diễn giải học tập. Tỷ lệ chuyên cần và điểm đánh giá có thể giúp xác định nhóm khóa học cần được xem xét thêm. Dữ liệu mô phỏng không đủ để kết luận nguyên nhân điểm thấp; cần có thông tin lớp học, giáo viên, độ khó bài kiểm tra và bối cảnh học viên.

11.4. Diễn giải tư vấn. Số buổi theo loại tư vấn có thể phản ánh nhu cầu dịch vụ. Nếu tỷ lệ 'Cần tư vấn thêm' cao, trung tâm có thể xem xét quy trình theo dõi, nhưng chỉ sau khi xác minh định nghĩa outcome và cách nhân viên ghi nhận.

11.5. Khuyến nghị quản trị. (i) Chuẩn hóa định nghĩa KPI dùng chung; (ii) thiết lập quy trình kiểm tra dữ liệu trước khi công bố dashboard; (iii) theo dõi chất lượng lead cùng với số lượng lead; (iv) đối chiếu doanh thu với chính sách hoàn/hủy; (v) kết hợp chỉ số học tập với cỡ mẫu và bối cảnh; (vi) lưu lịch sử thay đổi dữ liệu và định nghĩa.

11.6. Tránh suy diễn. Vì dữ liệu nhân tạo, các nhận xét về kênh, môn học hoặc nhóm học viên chỉ là minh họa phương pháp. Không sử dụng số liệu trong bộ này để quyết định ngân sách, học phí hoặc chính sách tư vấn ngoài đời.

12. QUẢN TRỊ DỮ LIỆU, BẢO MẬT VÀ RỦI RO

12.1. Quyền truy cập. Nên phân tách quyền nạp dữ liệu, biến đổi, quản trị dataset và xem dashboard. Người dùng BI chỉ cần quyền đọc Data Mart đã được phê duyệt, không nhất thiết được xem dữ liệu Bronze.

12.2. Tối thiểu hóa dữ liệu. Chỉ thu thập trường cần thiết cho câu hỏi phân tích. Hạn chế dữ liệu định danh trực tiếp. Nếu triển khai với dữ liệu học viên thật, phải tuân thủ quy định bảo vệ dữ liệu cá nhân và chính sách của tổ chức.

12.3. Quản lý bí mật. Không đưa mật khẩu, token, khóa service account hoặc thông tin xác thực vào notebook, báo cáo, Git hay Google Drive chia sẻ công khai. Sử dụng OAuth hoặc secret manager theo hướng dẫn của nền tảng.

12.4. Chất lượng và lineage. Mỗi KPI cần có định nghĩa, nguồn dữ liệu, phép biến đổi, chủ sở hữu và lịch cập nhật. Khi kết quả thay đổi, lineage giúp truy tìm mô hình hoặc nguồn gây sai lệch.

12.5. Rủi ro chính. Rủi ro gồm khóa không nhất quán, join làm nhân bản số tiền, khác biệt định nghĩa trạng thái, dữ liệu đến muộn, schema thay đổi, sai cấu hình location, chi phí truy vấn cloud và dashboard dùng dữ liệu cũ.

12.6. Giảm thiểu. Dùng khóa thay thế khi cần, test uniqueness/relationships, tổng hợp trước khi join dữ liệu khác grain, kiểm tra freshness, lưu log và giới hạn quyền truy cập. Thêm cảnh báo khi nguồn thiếu hoặc số dòng thay đổi bất thường.

13. PHÂN CÔNG CÔNG VIỆC NHÓM

Nhóm gồm 2 thành viên. Tên, MSSV và tỷ lệ/mức đóng góp cần được nhóm điền theo thông tin thực tế; báo cáo mẫu không tự giả định danh tính hoặc mức đóng góp. Phân công dưới đây là phương án đề xuất để tránh một người phải chịu trách nhiệm toàn bộ pipeline.

Thành viên 1 — phụ trách dữ liệu và mô hình: khảo sát dữ liệu, từ điển dữ liệu, profiling, quy tắc làm sạch, Star Schema, thiết kế Fact/Dimension và rà soát tính đúng đắn của KPI. Sản phẩm: notebook, data dictionary, sơ đồ mô hình và tài liệu mô tả dữ liệu.

Thành viên 2 — phụ trách triển khai và BI: cấu hình BigQuery/dbt, SQL Data Mart, dashboard, kiểm thử truy vấn, tài liệu hướng dẫn chạy và slide demo. Sản phẩm: project scaffold, SQL/dbt models, dashboard và phần kết quả kỹ thuật.

Cả hai thành viên cùng chịu trách nhiệm tích hợp báo cáo, kiểm tra chéo kết quả, trình bày trước lớp và thống nhất bảng đánh giá đóng góp. Phân công có thể thay đổi tùy năng lực và công việc thực tế; nên lưu lại lịch sử công việc để việc đánh giá minh bạch.

Bảng đánh giá theo mẫu giảng viên: MSSV [điền]; Họ và tên [điền]; Vai trò [điền]; Mức đóng góp [nhóm thống nhất]. Mức 1 là cao nhất theo hướng dẫn đề bài. Không nên tự động coi nhóm trưởng là người đóng góp cao nhất nếu chưa có đánh giá thống nhất.

14. KẾ HOẠCH THỰC HIỆN VÀ TIẾN ĐỘ

Giai đoạn 1 — chốt bài toán và KPI: thống nhất các câu hỏi kinh doanh, định nghĩa trạng thái, grain và phạm vi dữ liệu. Đầu ra là sơ đồ nghiệp vụ và data dictionary.

Giai đoạn 2 — dữ liệu và profiling: chạy notebook, kiểm tra raw, ghi nhận lỗi và tạo Silver. Đầu ra là các CSV, bảng thống kê chất lượng và biểu đồ khám phá.

Giai đoạn 3 — mô hình kho dữ liệu: tạo datasets, nạp dữ liệu, thiết kế dimension/fact, kiểm thử quan hệ. Đầu ra là sơ đồ Star Schema và SQL có thể chạy.

Giai đoạn 4 — dbt và Data Mart: cấu hình project, chạy models và tests. Đầu ra là log dbt, bảng Gold và các view phân tích.

Giai đoạn 5 — dashboard: chạy Streamlit local hoặc kết nối BI với BigQuery. Đầu ra là dashboard và mô tả KPI.

Giai đoạn 6 — báo cáo và thuyết trình: chèn kết quả thật, ảnh chụp, hoàn thiện phần hạn chế, rà soát định dạng và tập trình bày trong 10 phút.

Điểm kiểm soát quan trọng: không viết kết luận về kết quả cloud trước khi chạy; không chèn ảnh minh họa giả làm bằng chứng; không đưa thông tin cá nhân hoặc thông tin xác thực vào file nộp.

15. KẾT LUẬN

Đồ án đã xây dựng một thiết kế tham chiếu cho nhà kho dữ liệu tích hợp hoạt động marketing, lead, đăng ký, học tập và tư vấn hướng nghiệp tại trung tâm đào tạo. Kiến trúc nhiều lớp giúp tách dữ liệu nguồn khỏi dữ liệu chuẩn hóa và dữ liệu phân tích. Star Schema làm rõ grain và hỗ trợ tổng hợp theo thời gian, học viên, khóa học và chiến dịch.

Đóng góp chính của bộ khung gồm dữ liệu mô phỏng có lỗi chất lượng để kiểm thử, từ điển dữ liệu, notebook Python, mã SQL tạo bảng, project dbt khởi tạo, dashboard local và mẫu báo cáo/thuyết trình. Bộ khung giúp nhóm có điểm xuất phát nhất quán và có thể tái lập kết quả ở môi trường local.

Hạn chế lớn nhất là dữ liệu hoàn toàn mô phỏng, chưa có dữ liệu nghiệp vụ thực; chưa có Google Cloud Project nên triển khai BigQuery/dbt cloud chưa được xác minh; dashboard hiện đọc CSV local; quy tắc ghi nhận doanh thu là giả định minh họa; mô hình chưa bao phủ đầy đủ lịch sử thay đổi và orchestration.

Hướng phát triển gồm nạp dữ liệu thực đã được phép sử dụng, thêm audit log/quarantine, triển khai incremental models, SCD Type 2, phân vùng và clustering, điều phối bằng Airflow/Prefect, kết nối dashboard trực tiếp với BigQuery và bổ sung kiểm soát chi phí. Khi có dữ liệu đủ tin cậy, có thể nghiên cứu phân tích cohort, retention hoặc dự báo, nhưng phải đánh giá chất lượng và tính công bằng trước khi ứng dụng.

Kết luận cuối cùng về hiệu quả chỉ nên được hoàn thiện sau khi nhóm chạy toàn bộ notebook, kiểm tra các tệp Silver, tạo bảng Gold, chạy test và chèn kết quả thực nghiệm thật. Các số liệu mô phỏng trong bộ dữ liệu có giá trị minh họa kỹ thuật, không phải bằng chứng về hiệu quả của một trung tâm đào tạo ngoài đời.

PHỤ LỤC A — CẤU TRÚC BỘ DỮ LIỆU

Tệp students.csv: một dòng/học viên; khóa student_id. Tệp campaigns.csv: một dòng/chiến dịch; khóa campaign_id. Tệp leads.csv: một dòng/lead; khóa lead_id; có student_id và campaign_id. Tệp enrollments.csv: một dòng/lượt đăng ký; khóa enrollment_id; có student_id, campaign_id, course_id và lead_id tùy trường hợp.

Tệp courses.csv: một dòng/khóa học; khóa course_id. Tệp learning_records.csv: một dòng/buổi học hoặc lần ghi nhận; khóa learning_record_id; liên kết enrollment_id, student_id và course_id. Tệp career_guidance.csv: một dòng/buổi tư vấn; khóa guidance_id; liên kết student_id.

Thư mục data/raw giữ dữ liệu nguồn mô phỏng có một số lỗi được cài đặt có chủ đích. Thư mục data/silver giữ dữ liệu sau xử lý bằng cùng bộ quy tắc đã mô tả. Data dictionary.xlsx liệt kê tên cột, kiểu dữ liệu logic, mô tả và quy tắc chất lượng.

Để kiểm tra số dòng và chất lượng, chạy notebook từ đầu đến cuối. Nếu chỉnh sửa dữ liệu hoặc quy tắc, ghi lại phiên bản và tái tạo đầu ra để tránh báo cáo không khớp với code.

PHỤ LỤC B — CÁC TRUY VẤN KPI MẪU

Lead conversion: đếm lead_id duy nhất và lead_id có lead_status = 'Converted', sau đó dùng SAFE_DIVIDE để tránh chia cho 0. Phải chuẩn hóa trạng thái trước khi tính.

Doanh thu ghi nhận: tổng recognized_revenue_vnd từ Fact_Enrollment. Trong giả định hiện tại, đơn Cancelled/Refunded đóng góp 0. Khi áp dụng thực tế, cần xác định chính sách kế toán, thời điểm ghi nhận và xử lý hoàn tiền.

Attendance rate: số buổi Present chia tổng số buổi có trạng thái hợp lệ. Cần loại bản ghi trùng và đảm bảo mỗi learning_record_id chỉ đại diện một sự kiện.

Average assessment score: AVG(assessment_score) trên điểm hợp lệ 0–10. Cần hiển thị cỡ mẫu và không thay điểm thiếu bằng 0 vì điều đó làm sai lệch trung bình.

Cost per lead: marketing spend ở grain campaign chia tổng lead ở campaign. Không được sum marketing_spend sau khi join campaign với nhiều lead nếu chưa tổng hợp về grain chiến dịch.

PHỤ LỤC C — HƯỚNG DẪN TÁI LẠP

Bước 1: giải nén thư mục dự án. Bước 2: chạy notebook trong Google Colab hoặc Jupyter, sửa RAW_DIR thành vị trí dữ liệu nếu cần. Bước 3: kiểm tra các tệp trong data/silver và lưu kết quả profiling. Bước 4: tạo GCP Project, bật BigQuery API và tạo datasets.

Bước 5: upload các CSV vào Bronze với tên bảng thống nhất. Bước 6: thay YOUR_GCP_PROJECT_ID trong source YAML và SQL. Bước 7: cài dbt-bigquery và thiết lập OAuth. Bước 8: chạy dbt debug, dbt run, dbt test; xử lý lỗi theo log.

Bước 9: chạy dashboard local bằng Streamlit. Bước 10: chụp ảnh kết quả thật, bổ sung số liệu và bằng chứng vào báo cáo, thay placeholder nhóm và thành viên, kiểm tra font 13 và số trang. Bước 11: lưu bản DOCX/PDF cuối và đường dẫn thư mục Drive theo yêu cầu giảng viên.

Không chia sẻ project ID nếu chính sách nhóm yêu cầu riêng tư; tuyệt đối không chia sẻ credential. Chỉ công khai tệp dữ liệu mô phỏng và mã nguồn không chứa bí mật.

PHỤ LỤC D — BẢNG ĐÁNH GIÁ CÔNG VIỆC

Thành viên 1: MSSV [điền]; Họ tên [điền]; công việc dự kiến: dữ liệu nguồn, profiling, làm sạch, từ điển dữ liệu, thiết kế Star Schema; mức đóng góp do cả nhóm thống nhất.

Thành viên 2: MSSV [điền]; Họ tên [điền]; công việc dự kiến: SQL/dbt, Data Mart, dashboard, kiểm thử triển khai và slide; mức đóng góp do cả nhóm thống nhất.

Cả nhóm: tích hợp báo cáo, rà soát code, xác minh số liệu, tập thuyết trình và thống nhất mức đánh giá. Bảng cuối cùng phải phản ánh công việc đã thực hiện, không chỉ dựa trên phân công ban đầu.